Temiz Veri Dosyası: Veri Kalitesi Notu

ASA Data Quest 2026 · Görev 1 (Veri kalitesi) · Hazırlayan: Serengül Kara · Dosya: `wpp2024_ulke_temiz.csv`

1. Yapı doğrulaması (kodla yapıldı)

Kontrol	Sonuç
Satır × sütun	35.787 × 64
Benzersiz ülke (`LocID` , `ISO3_code` , `Location`)	237 / 237 / 237, `ISO3_code` boş değer yok
Yıl aralığı	1950–2100, 151 benzersiz yıl
Ülke başına yıl sayısı	Her 237 ülkede 151
Yıl başına ülke sayısı	Her 151 yılda 237
Tekrarlayan (`LocID` , `Time`)	0
Tahmin / projeksiyon	`is_projection` 0: 1950–2023, 1: 2024–2100

237 ülke × 151 yıl = 35.787 satır, dosyadaki satır sayısıyla birebir eşleşiyor. Panel dengeli.

2. `small_territory` bayrağı

- Bayrağın dayandığı değişken `pop2023_thousands` (2023 nüfusu, bin kişi). Bayrak her ülkede yıldan bağımsız sabit.
- 76 ülke 1, 161 ülke 0.
- Bayrağı 1 olan ülkelerin en büyüğü Fiji (924,1 bin). Bayrağı 0 olan ülkelerin en küçüğü Cibuti (1.152,9 bin).
- Eşik bu iki değerin arasında. Büyük olasılıkla 1 milyon, ancak tam değer ve eşitliğin yönü (< ya da ⩽) dosyadan kesin olarak çıkarılamıyor.
- **Açık nokta:** Kesin eşik, temizleme dosyasını hazırlayan kişiden teyit edilecek.

3. `extreme_event_flag` bayrağı

- 19 satır 1 değerinde, 7 ülke. Hepsi 2023 ve öncesi (tahmin dönemi), hepsinde `small_territory` = 0.

- İşaretli ülke-yıllar: Kamboçya 1975–78, Orta Afrika Cumhuriyeti 2009 ve 2022, Kuzey Kore 1950–51, Güney Kore 1950, Ruanda 1994, Güney Sudan 1987/88/92/93/98, Doğu Timor 1975 ve 1977–79.
- Bayrağın kuralı dosyadan çıkarılamadı. Büyüme hızı, ölüm oranı ya da yaşam beklentisi düşüşüne dayanan basit bir eşikle uyuşmuyor. Örneğin Kuveyt 1990, Bosna 1992 ve Somali 1991 işaretsiz.
- **Açık nokta:** Bayrağın tanımı ve işaretli satırların veride bilerek mi bırakıldığı, temizleme dosyasını hazırlayan kişiden netleştirilecek. Raporda şimdilik "dosyada gözlenen" olarak belgelenecek.

4. Seri sonu ve temizleme kodu

- Dosya 2100'de bitiyor. Getting Started rehberi 1950–2101 yazıyor. 2101'in bilerek çıkarılıp çıkarılmadığı dosyadan anlaşılamıyor, teyit bekliyor.
- Temizleme kodu repoda görünmüyor. `01_veri_hazirlik.py` bu iki bayrağı üretmiyor, yalnızca temiz dosyadan okuyup taşıyor.

5. Analizlere etkisi

- Bölge medyanları `small_territory`'ye duyarlı. Okyanusya'da 23 ülkenin 20'si küçük işaretli, 2023 yaşam süresi medyanı tüm ülkelerde 71,7, küçükler hariç 82,1. Raporda hangi seçimin kullanıldığı açıkça yazılmalı.
- `extreme_event_flag` ortak veri hazırlığında filtre olarak kullanılmıyor, profil dosyasına taşınıyor.

6. Bekleyen teyitler

1. `small_territory` için kesin eşik değeri ve eşitliğin yönü.
2. `extreme_event_flag` için kural ve işaretli satırların veride bırakılma gerekçesi.
3. 2101 yılının neden dahil edilmediği.